



PATRON ML

Patrones de Comportamiento en Trastornos del Neurodesarrollo

Detección de TDAH en población infantil mediante Machine Learning

Autor: Daniel Carrasco Moreno

Directores: Alberto Fernández Hilario, José Manuel Soto Hidalgo

E.T.S Ingenierías Informática y de Telecomunicación, Grado en Ingeniería Informática.

Universidad de Granada

Granada, Noviembre 2025



**UNIVERSIDAD
DE GRANADA**

ETSIIT

Escuela Técnica Superior
de Ingenierías Informática
y de Telecomunicación



Resumen



Introducción & Contexto

El problema del TDAH y propuesta de solución



Metodología

Pipeline riguroso y arquitectura dual



Análisis Experimental

Hallazgos, variables clave y resultados



Desarrollo Aplicación

TDAHTool: sistema operativo y funcional



Resultados & Futuro

Conclusiones y líneas de trabajo

Introducción

Análisis Experimental

Resultados & Futuro

Metodología

Desarrollo Aplicación

El Problema: TDAH en la Infancia

Magnitud del Desafío

- Afecta al 5-12% de la población infantil mundial
- En España: prevalencia aproximada del 6.8%, con mayor incidencia en varones
- En EEUU la prevalencia es del 10% de la población infantil
- El diagnóstico actual se basa en **procedimientos subjetivos**: entrevistas clínicas, escalas de valoración y observación conductual

Consecuencias Actuales

- Retrasos diagnósticos que postergan intervenciones críticas
- Variabilidad en criterios clínicos entre profesionales
- Falta de herramientas objetivas de apoyo a la decisión



- **Necesidad identificada:** desarrollar herramientas objetivas y transparentes que apoyen (no reemplacen) la decisión clínica especializada.

Introducción

Análisis Experimental

Resultados & Futuro

Metodología

Desarrollo Aplicación

Estado del Arte: Inspiración y Aportaciones

Trabajos Previos: Aprendizajes Clave

Trabajo	Dataset	Resultados	Aprendizaje
Maniruzzaman (2022)	NSCH 45K menores	Acc: 85%, AUC: 0.94	Viabilidad ML en NSCH
Slobodin (2020)	CPT 458 menores	Acc: 87%, Sens: 89%	Precisión con CPT
Zakani (2023)	Serious game 52 menores	Acc: 92%, Sens: 90%	"Potencial serious games"

De la Literatura → Aportaciones en PATRON ML

- 📚 Evidencia de viabilidad de ML en TDAH
→ 🎯 NSCH 2023 actualizado (55K casos representativos)
- 📚 Importancia de resultados cuantitativos sólidos
→ 🎯 Pipeline riguroso anti-fuga + validación estratificada
- 📚 Necesidad de comprensión del modelo
→ 🎯 Decision Tree interpretable + rutas explicables
- 📚 Valor de la transferencia práctica
→ 🎯 TDAHTool operativo (Docker + MLOps + interfaz web)

- ❑ **PATRON ML se construye sobre la evidencia existente y aporta interpretabilidad, rigor metodológico y operacionalización**

Introducción

Análisis Experimental

Resultados & Futuro

Metodología

Desarrollo Aplicación

Propuesta: PATRON ML

PATRON ML combina **ciencia de datos rigurosa, machine learning interpretable y desarrollo de aplicación operativa** para extraer patrones objetivos que apoyen la detección temprana del TDAH en entornos educativos y de atención primaria.



Datos Amplios

NSCH 2023: 55.162 menores,
variables clínicas y contextuales



Modelado Interpretable

Árbol de decisión calibrado con
explicabilidad local



Explicabilidad

Ruta de decisión y análisis what-if
interactivo



Aplicación Real

TDAHTool: API + UI, Docker, reproducible



MLOps Ligero

Trazabilidad completa, CI/CD, validación anti-leakage

Introducción

Análisis Experimental

Resultados & Futuro

Metodología

Desarrollo Aplicación

Arquitectura "Doble Carril"

La arquitectura separa deliberadamente la experimentación analítica del desarrollo operativo, permitiendo evolución independiente pero conectada de modelo y aplicación.

Carril 1: Data Science

Marco: **CRISP-DM**

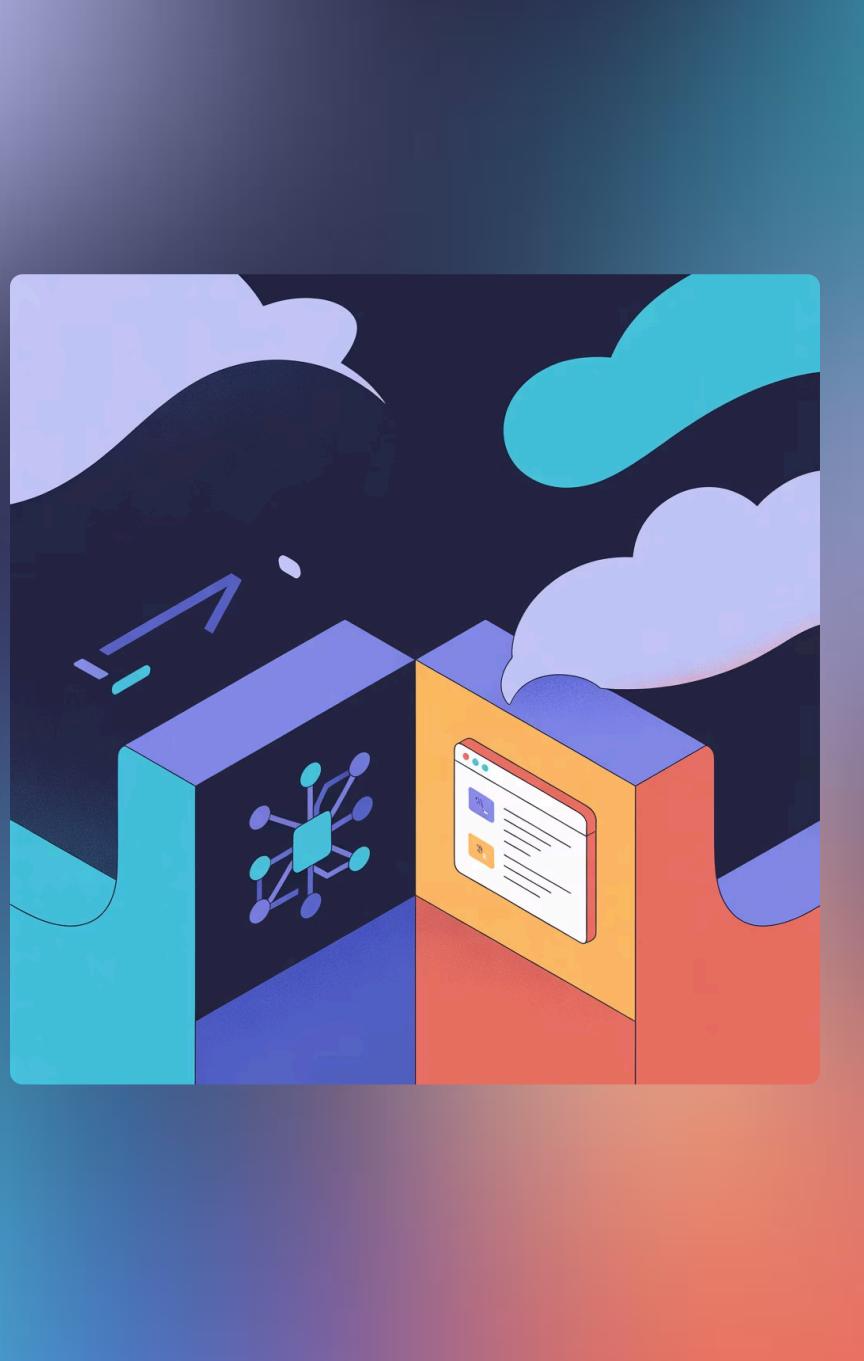
1. **Definición del problema** y objetivos
2. **Ingesta de datos** (NSCH 2023)
3. **Preprocesado** y limpieza rigurosa
4. **EDA & Feature Engineering** ($457 \rightarrow 49$ variables)
5. **Entrenamiento** con validación anti-leakage

Carril 2: App/DevOps

Marco: **MLOPS**

1. **API Backend** (FastAPI + validación)
2. **UI Frontend** (Streamlit interactivo)
3. **Orquestación** (Docker Compose)
4. **Despliegue** (local o cloud)

Punto de conexión: artefacto .pkl serializado con pipeline completo (preprocesado + modelo + calibración)





Preparación de Datos & Anti-Leakage



Políticas Anti-Fuga de Información

Medidas Implementadas

- Separación **train/test** completamente estricta desde el inicio con semillas fijas
- Transformaciones aprendidas **solo en train**, aplicadas sin recalcular en test
- Eliminación de variables "trampa" con correlación ≈ 1.0 con etiqueta
- Test holdout **retenido completamente** hasta evaluación final única

Variables Eliminadas

- adhdmedicatednum: correlación ~ 1.0 con diagnóstico
- memorycondbin: revelaba diagnóstico indirectamente
- Otras variables de diagnóstico explícito

▢ **Resultado:** métricas realistas y generalizables, no "perfectas" artificialmente

Introducción

Análisis Experimental

Resultados & Futuro

Metodología

Desarrollo Aplicación

Análisis Exploratorio y Feature Engineering



82 Variables Candidatas

Primera selección basada en relevancia clínica + preprocesamiento



Fusiones Semánticas

Combinación de diagnóstico + estado + severidad



Análisis Descriptivo

Transformación de variables para mitigación de outliers



Análisis de Correlaciones

Spearman, Chi-cuadrado, Biserial: validación estadística



49 Variables Finales

Interpretables, correlacionadas, sin fuga de información.

Fusiones Semánticas Principales

- conducta_status_num = diagnóstico + estado + severidad de problemas de conducta
- ansiedad_status_num = diagnóstico + estado + severidad de ansiedad
- educacion_especial_status_num = acceso a IEP y apoyos educativos especiales



Modelo Elegido: Árbol de Decisión

En contexto clínico y educativo, la **interpretabilidad no es un lujo, es una necesidad**. Los profesionales requieren comprender el razonamiento detrás de cada predicción.

Criterio	Decision Tree	Random Forest	SVM
Interpretabilidad	✓ Excelente	⚠ Media	✗ Baja
Explicabilidad Local	✓ Ruta visible	✗ Caja negra	✗ Caja negra
Detección Interacciones	✓ Automática	✓ Automática	⚠ Manual
Desempeño	✓ Competitivo	✓ Alto	✓ Alto

- **Decisión estratégica:** priorizamos explicabilidad sobre 2-3% adicional de accuracy. La ruta de decisión visible es accionable para profesionales educativos y clínicos.

Introducción

Análisis Experimental

Resultados & Futuro

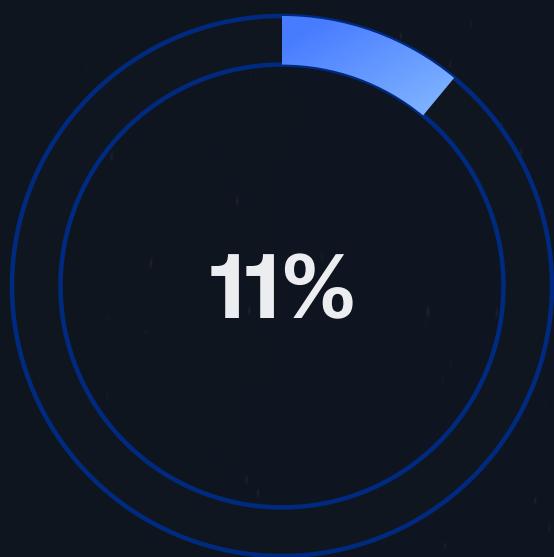
Metodología

Desarrollo Aplicación

Desafío Crítico: Manejo del Desbalance de Clases (TDAH)

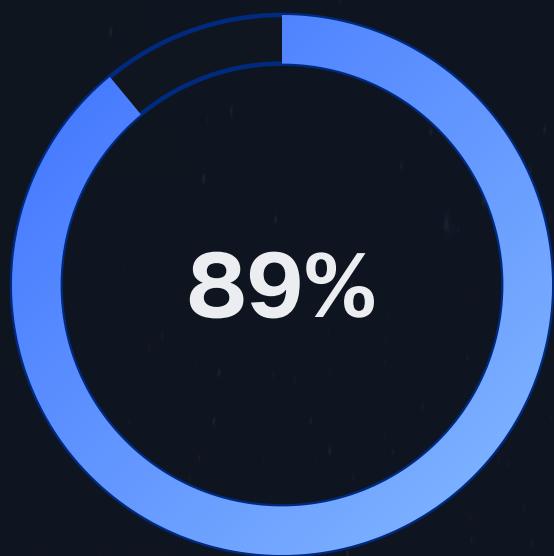
CONTEXTO Y DESAFÍO

Desbalance Severo: Dataset NSCH 2023



TDAH Positivo

Clase minoritaria



No TDAH

Clase mayoritaria

DECISIONES METODOLÓGICAS

- **Ponderación de Clases:** Parámetro `class_weight='balanced'`
 - Ajusta función de pérdida para dar más peso a clase minoritaria (TDAH)
 - Evita datos sintéticos (como SMOTE), mantiene rigor metodológico
- **Calibración Probabilística:** `CalibratedClassifierCV`
 - Corrige tendencia de Árboles de Decisión a probabilidades mal ajustadas
 - Obtiene estimaciones fiables para decisiones clínicas
- **Nota:** Undersampling usado solo preliminarmente para importancia de variables, no en modelo final.

CRITERIO DE OPTIMIZACIÓN Y UMBRAL

- **Métrica Principal:** **F1-score** como métrica objetivo (media armónica Precisión-Recall)
- **Ajuste de Umbral (τ):** No mantenido en 0.5
 - Seleccionado τ que maximiza F1-score clase TDAH en curva Precision-Recall
- **Conclusión Operativa:** Equilibrio que prioriza sensibilidad sin disparar falsos positivos

Objetivo Clínico: Equilibrio óptimo entre:

- Minimizar **Falsos Negativos** (alta Sensibilidad/Recall - no dejar pasar casos TDAH)
- Minimizar **Falsos Positivos** (alta Precisión - evitar saturación del sistema)





Del Modelo Base al Modelo Final: Pipeline de Entrenamiento



Introducción

Análisis Experimental

Resultados & Futuro

Metodología

Desarrollo Aplicación

Las 12 Variables Predictivas Clave

El árbol identifica **12 variables fundamentales** que capturan dimensiones conductuales, de salud mental y contextuales coherentes con la literatura clínica sobre TDAH.

● Señales Conductuales Nucleares (variable más importante)

- **Problemas de Conducta:** impulsividad, desobediencia y oposición estrechamente ligados al TDAH
- **Finalización de Tareas:** déficit atencional característico
- **Frecuencia Discusiones:** impulsividad conductual

● Impacto Funcional y Social

- **Interferencia Actividades:** impacto funcional cotidiano
- **Facilidad Hacer Amigos:** habilidades sociales afectadas

● Variables Clínicas

- **Comorbilidad Ansiedad:** presente en 25-40% casos TDAH
- **Educación Especial:** acceso a IEP y apoyos especiales como proxy de necesidades educativas

● Contexto Sociodemográfico

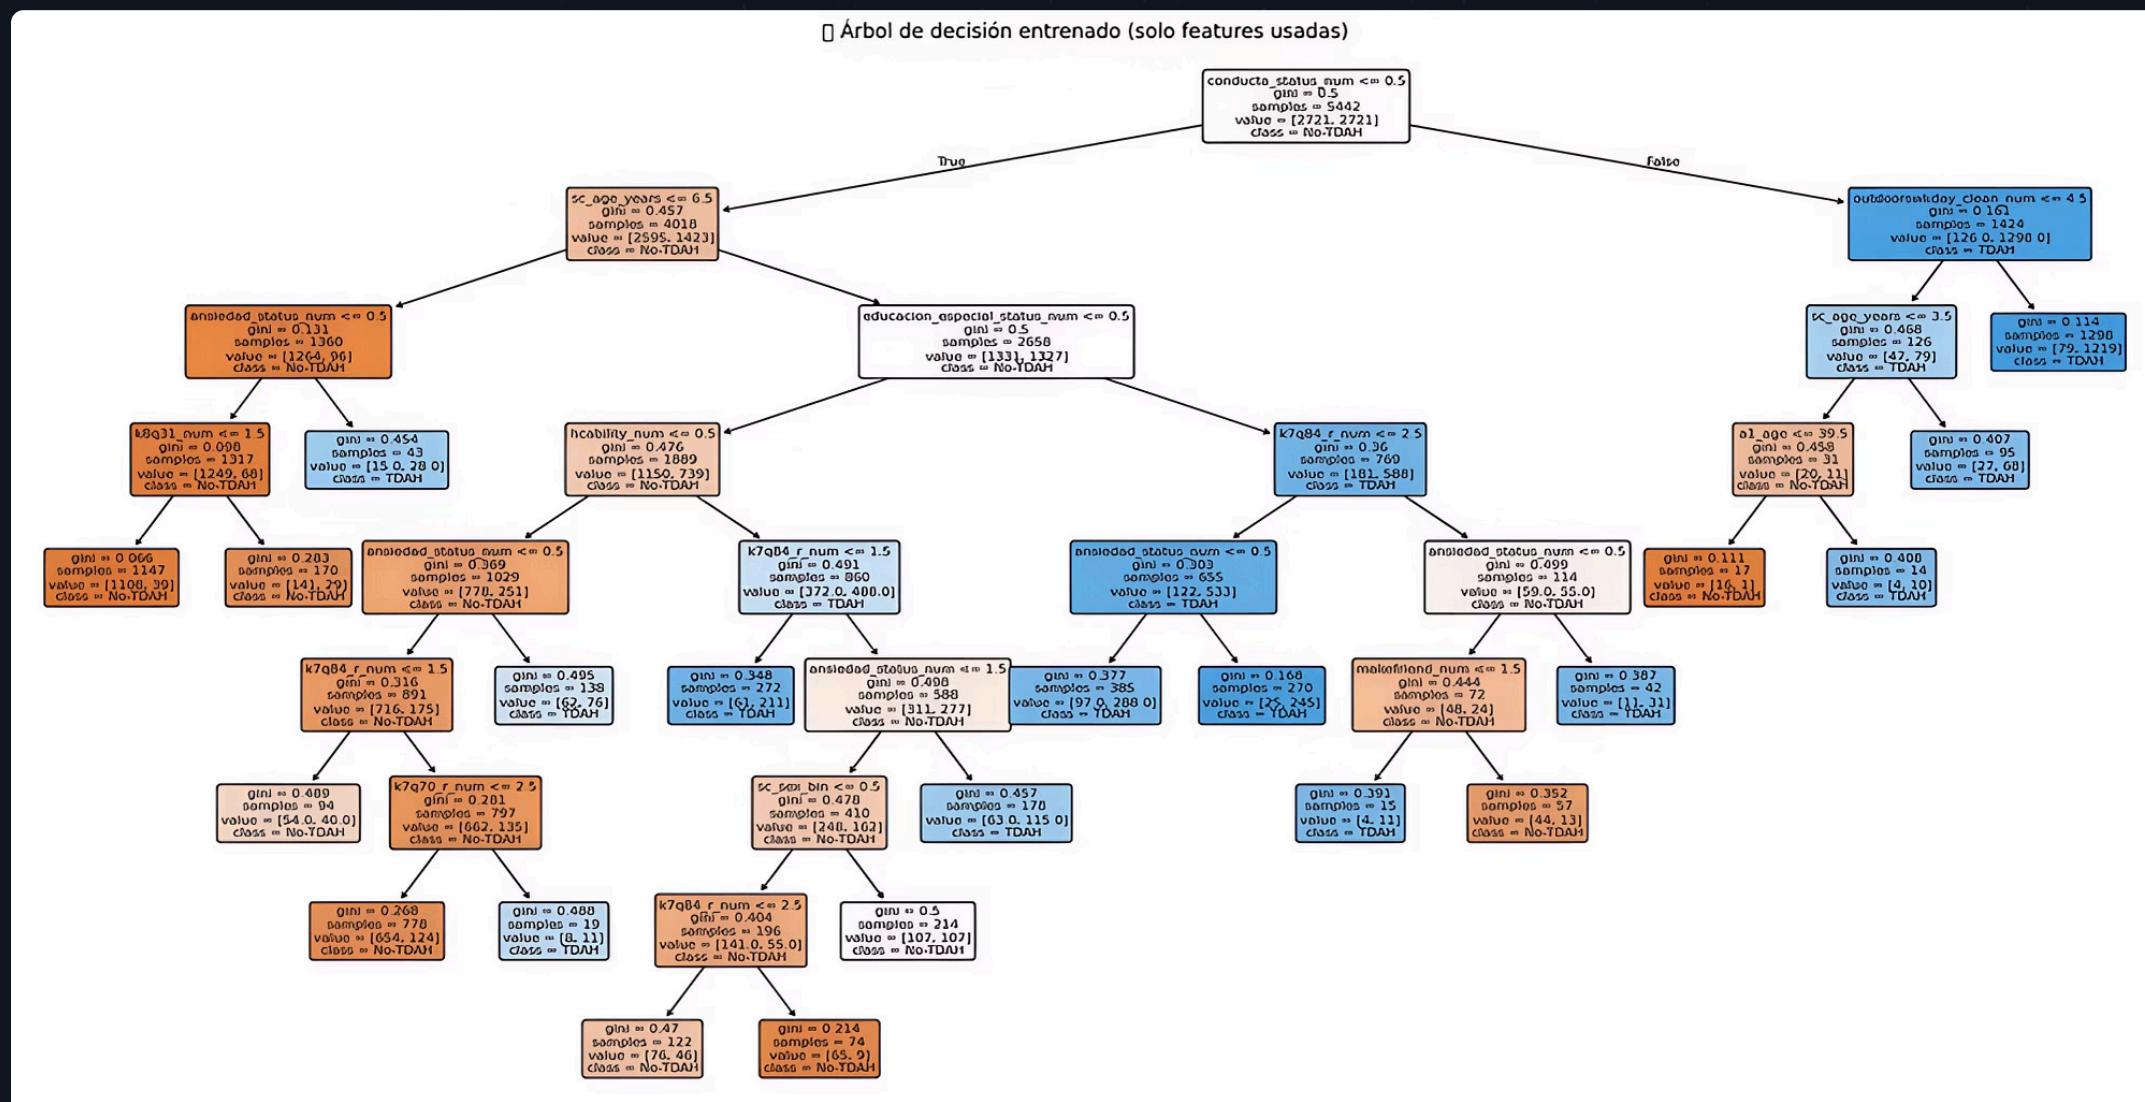
- **Edad del Menor:** expresión clínica varía según etapa del desarrollo
- **Sexo del Menor:** mayor prevalencia en varones
- **Tiempo al Aire Libre:** relacionado con autorregulación
- **Dificultad Cuidados:** impacto en contexto familiar
- **Edad Cuidador (madre):** factor de contexto familiar

Metodología

Desarrollo Aplicación

Árbol de Decisión Definitivo

Interpretación clínica del clasificador final (12 variables)



Estructura Clave

- Nodo raíz:** Problemas de Conducta (umbral ≈ 0.5) - predictor más potente
- Rama ≤ 0.5 :** Alta pureza "No TDAH"
- Rama > 0.5 :** Distribución hacia "TDAH"

Variables Principales

- Conducta:** Disparador principal
- Persistencia Tareas:** Ajusta riesgo en incertidumbre
- Ansiedad:** Comorbilidad discriminativa
- Tiempo Aire Libre:** En conducta problemática $\rightarrow 94\%$ TDAH

Patrones Clínicos

- ✓ Mayor TDAH:** Conducta problemática + baja finalización tareas + ansiedad
- ✓ Mayor No TDAH:** Sin problemas conducta + baja interferencia + cuidado fácil

Interpretabilidad: Cada ruta clínicamente plausible y explicable para profesionales

Introducción

Análisis Experimental

Resultados & Futuro

Metodología

Desarrollo Aplicación

Resultados en Test

Evaluación final sobre **conjunto de test completamente retenido** (~7.000 muestras), garantizando métricas reales de generalización.

0.70

Recall (TDAH)

Detectamos 70% de casos TDAH reales

0.98

Especificidad

Solo 2% de falsos positivos

0.61

F1-Score

Balance robusto detección-precisión

0.54

Precision

54% de predicciones TDAH son correctas

0.82

ROC-AUC

Buena capacidad discriminativa

✓ Fortalezas

- **Alto Recall:** detectamos 70% de casos TDAH reales, evitando muchos falsos negativos
- **Alta Especificidad:** muy pocos falsos positivos (98% corrección en negativos)
- **Equilibrio F1:** balance armónico entre detección y precisión
- **Generalización validada:** ROC-AUC de 0.82 confirma capacidad discriminativa

⚠ Limitaciones

- **Falsos negativos:** aún perdemos ~30% de casos TDAH sin detectar
- **Precisión moderada:** 54% refleja el desafío inherente de datos desbalanceados y la complejidad del diagnóstico TDAH
- **Punto de partida:** modelo no es solución final, requiere mejora continua
- **Validación local:** necesaria replicación en muestras españolas/europeas

Estos resultados son **realistas** en escenario desbalanceado con datos de cuestionarios

Introducción

Análisis Experimental

Resultados & Futuro

Metodología

Desarrollo Aplicación

Comparación de Escenarios de Variables

Evaluamos tres configuraciones de variables para identificar el **mejor equilibrio** entre rendimiento, interpretabilidad y mantenibilidad.

Escenario	Nº Variables	Recall	Precisión	F1	Resultado
Experto (restrictivo)	24	0.42	0.49	0.45	⚠ Pierde señal
Completo (exhaustivo)	82	0.70	0.54	0.61	⚠ Ruido adicional
Híbrido (óptimo)	49	0.70	0.54	0.61	✓ Mejor balance

Escenario Experto (24 vars)

Demasiado restrictivo: variables seleccionadas solo por criterio clínico pierden patrones sutiles presentes en los datos

Escenario Completo (87 vars)

Exceso de variables: introduce ruido sin mejora sustancial en métricas, dificulta interpretabilidad

Escenario Híbrido (49 vars)



Selección óptima: combina EDA riguroso, criterio clínico, importancia de modelo y validación empírica



Arquitectura TDAHTool



TDAHTool implementa una **arquitectura desacoplada** que separa backend (lógica de ML) y frontend (interfaz de usuario), permitiendo evolución independiente y reusabilidad.

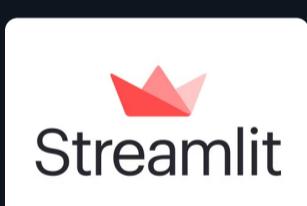


User Final

Docente, orientador educativo o clínico de atención primaria

UI Frontend (Streamlit)

Formulario interactivo, explorador what-if, visualización árbol



API Backend (FastAPI)

Validación Pydantic, preprocesado, predicción, ruta de decisión



Pipeline ML (.pkl)

Modelo calibrado + esquema de datos + métricas (solo lectura)

Ventajas Arquitectónicas

- **Independencia:** modelo y aplicación evolucionan por separado
- **Reusabilidad:** API consumible por otros clientes (móvil, web, etc.)
- **Escalabilidad:** frontend y backend se escalan independientemente
- **Reproducibilidad:** Docker Compose + versionado Git



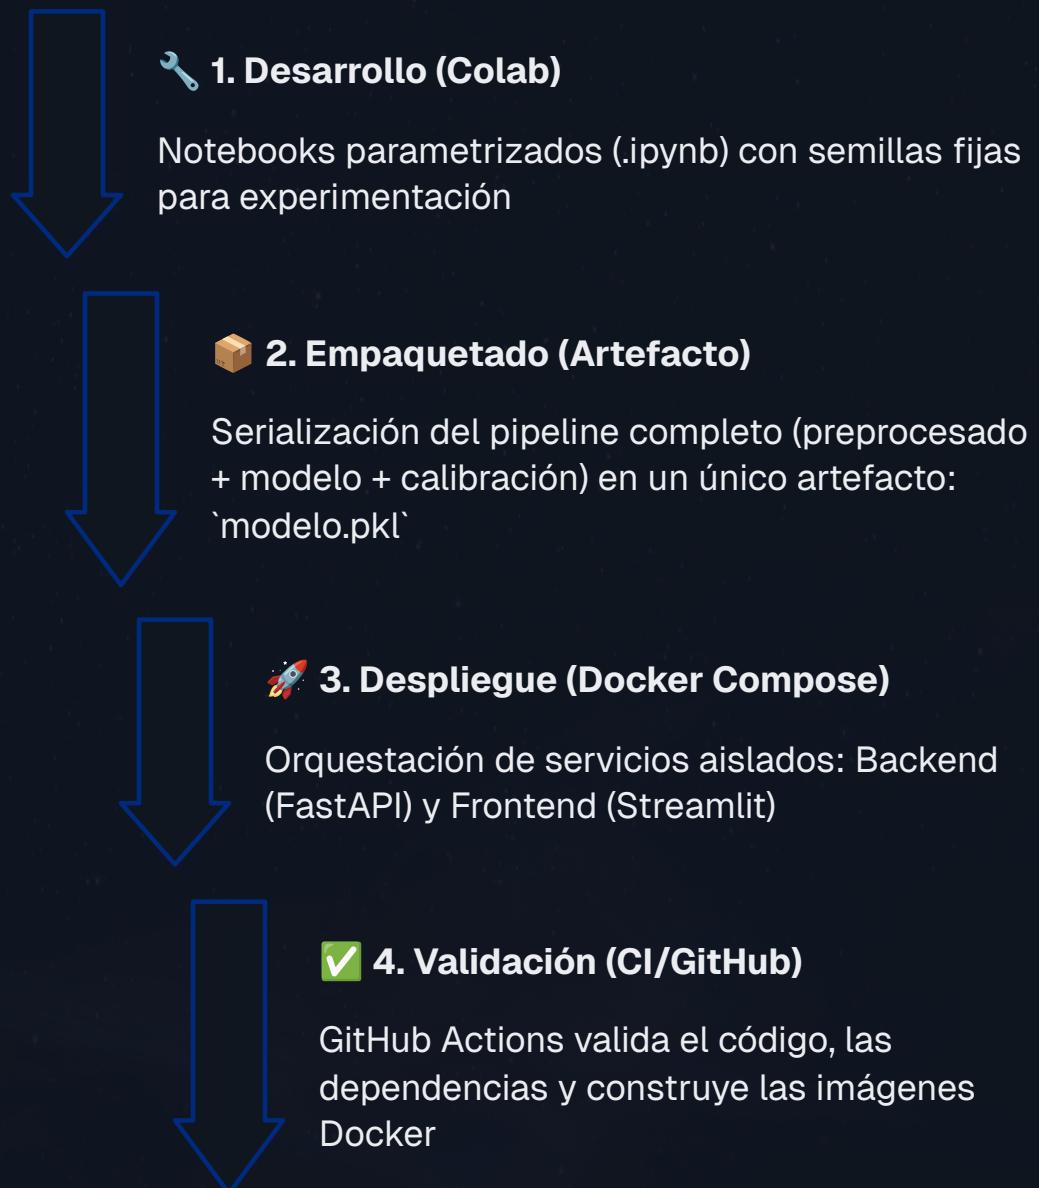
Despliegue y MLOps Ligero

MLOPS en PATRON ML

MLOps es la práctica que conecta nuestro "Carril 1: Data Science" con el "Carril 2: App/DevOps". En PATRON ML, implementamos un enfoque de **MLOps Ligero**, centrado en tres objetivos clave:

- **Reproducibilidad:** Asegurar que los experimentos se puedan repetir, utilizando semillas fijas y notebooks parametrizados.
- **Trazabilidad:** Versionar todo el ciclo (código, datos y modelos) con GitHub, para un historial claro de "quién hizo qué y por qué".
- **Entrega Confiable:** Crear un "contrato" (el artefacto .pkl) que la aplicación consume de forma estable y aislada con Docker.

Nuestro Pipeline de MLOps Ligero



Introducción

Análisis Experimental

Resultados & Futuro

Metodología

Desarrollo Aplicación

Funcionalidades Interactivas

TDAH Tool – Demo

API conectada

Introducir datos y obtener predicción

F_Estado de conducta del paciente: Nunca diagnosticado | F_Dificultad para cuidar al paciente: Nunca

E_Edad del paciente (años): 10 | E_El paciente discute mucho: Nunca

F_Año de nacimiento: 2015 | E_Estado de ansiedad en el paciente: Nunca diagnosticado

F_Estado de servicios de educación especial: Nunca ha tenido plan especial de educ... | F_Persistencia del paciente para finalizar las tareas: Nunca

F_Condiciones de salud presentes en el paciente: El menor no presenta problemas de salud | E_Dificultad para hacer amigos: Mucho

E_Sexo del paciente: Femenino | E_Tiempo de juego del paciente (entre semana): Muy joven (<3 años)

Mover controles y visualizar cómo cambia la probabilidad

E_Estado de conducta del paciente: Nunca diagnosticado | E_Dificultad para cuidar al paciente: Nunca

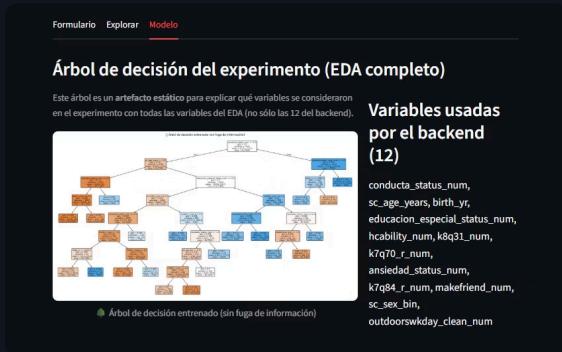
E_Edad del paciente (años): 10 | E_El paciente discute mucho: Nunca

E_Año de nacimiento: 2015 | E_Estado de ansiedad en el paciente: Nunca diagnosticado

E_Estado de servicios de educación especial: Nunca ha tenido plan especial de educ... | E_Persistencia del paciente para finalizar las tareas: Nunca

E_Condiciones de salud presentes en el paciente: El menor no presenta problemas de salud | E_Dificultad para hacer amigos: Mucho

E_Sexo del paciente: Femenino | E_Tiempo de juego del paciente (entre semana): Muy joven (<3 años)



Vista 1: Formulario de Predicción

- Entrada:** 12 variables clave mapeadas a categorías clínicas
- Salida:** Probabilidad calibrada + ruta completa de decisión del árbol
- Explicabilidad:** Usuario ve exactamente por qué el modelo decide

Vista 2: Explorador What-If

- Funcionalidad:** Modificar variables interactivamente y ver cambios en tiempo real
- Utilidad:** Responder "¿Qué pasaría si...?" para análisis de sensibilidad
- Ánalisis:** Identificar variables de mayor impacto por caso

Vista 3: Visualización del Modelo

- Visualización:** Árbol completo con nodos coloreados por probabilidad
- Propósito:** Transparencia global y herramienta educativa
- Navegación:** Zoom, pan, resultado de rutas específicas

Introducción

Análisis Experimental

Resultados & Futuro

Metodología

Desarrollo Aplicación

Síntesis de Hallazgos Principales

Logros Metodológicos

1

Pipeline Riguroso

Separación estricta train/val/test, validación anti-leakage completa

2

Interpretabilidad Real

Árbol + ruta local + what-if → explicabilidad accionable

3

Gestión Desbalance

class_weight + calibración + umbral → F1-score robusto

4

Reproducibilidad

Semillas fijas, versionado, Docker, CI/CD

5

Transferencia Operativa

App web funcional, no solo análisis académico

Logros Experimentales

49

**Variables
Potencialmente
Determinadoras**

De las cuales 12 se usan en el modelo final.

De 457 iniciales, identificadas dimensiones clínicas claras

0.98

Especificidad

Solo 2% falsas alarmas

0.70

Recall TDAH

Detectamos 70% casos reales

0.82

ROC-AUC

Discriminación validada

PATRON ML logra: metodología rigurosa y reproducible + modelo realista y operativo + explicabilidad real para profesionales



Líneas de Trabajo Futuro

Corto Plazo: Validación Local

- Replicar con **muestras españolas y europeas**
- Ajustar a contextos locales (lengua, cultura, sistemas educativo/sanitario)
- Reportar métricas desagregadas por subgrupos (sexo, edad, nivel socioeconómico)

Mediano Plazo: Comparativas Rigurosas

- Entrenar **XGBoost, SVM, MLP** con mismo protocolo anti-leakage
- Medir ganancia real vs. árbol de decisión
- Mantener comparabilidad metodológica estricta

Largo Plazo: Usabilidad Operativa

- **Estudios con usuarios reales:** docentes, orientadores, atención primaria
- Iteración de interfaz basada en feedback directo
- Validación clínica operativa en entornos reales

1

2

3

4

5

Corto Plazo: Ampliación de Señales

- Integrar **historial académico** (calificaciones, asistencia, reportes docentes)
- Integrar **recomendaciones**: sugerencias de cuidado, recordatorios medicación, contacto con salud mental...
- Datos de sueño, actividad física, tiempo de pantalla
- Cuando sea ético y disponible: EEG, otros biomarcadores objetivos

Mediano Plazo: Auditoría de Equidad

- **Análisis de sesgos** por sexo, nivel socioeconómico, estructura familiar
- Aplicar técnicas fairness-aware si hay disparidades
- Reportes transparentes desagregados

Introducción

Análisis Experimental

Resultados & Futuro

Metodología

Desarrollo Aplicación

Conclusiones Finales

PATRON ML: Punto de Partida Sólido

Extracción de Patrones Objetivos

Demostramos que es posible extraer patrones TDAH desde datos poblacionales amplios con ML riguroso

Interpretabilidad Viable

No hay que elegir entre explicabilidad y rendimiento: el Árbol de Decisión ofrece ambas

Anti-Leakage Riguroso

Separación estricta train/val/test + validación estratificada y calibración producen métricas realistas y generalizables

Sistema Operativo Real

TDAHTool es reproducible, con explicabilidad local, listo para despliegue operativo

Metodología Reutilizable

Pipeline adaptable a futuras ediciones NSCH, datos locales o problemas afines en neurodesarrollo

*"PATRON ML no es la solución final al desafío de detección del TDAH. Es un **punto de partida sólido**, metodológicamente riguroso y operativamente útil. Valida que el Machine Learning puede apoyar la decisión clínica/educativa si se hace con disciplina: rigor en datos, interpretabilidad, reproducibilidad y honestidad sobre limitaciones. El futuro es iterar, replicar localmente y madurar la herramienta con usuarios reales."*



PATRON ML

Patrones de Comportamiento en Trastornos del Neurodesarrollo

Detección de TDAH en población infantil mediante Machine Learning

Autor: Daniel Carrasco Moreno

Directores: Alberto Fernández Hilario, José Manuel Soto Hidalgo

E.T.S Ingenierías Informática y de Telecomunicación, Grado en Ingeniería Informática.

Granada, Noviembre 2025



**UNIVERSIDAD
DE GRANADA**

